

Wan-Streamer 阶段性报告

数据构建、模型机制与验证结果 | 2026-08

1.项目目标和当前进展

项目目标是在有限数据和算力条件下，对 Wan-Streamer 的核心思路进行最小化实现。重点在于构建真实、因果对齐的多模态数据，并让模型在同一条时间线上共同学习文字、音频和视频的下一步状态。

当前路线融合了两份参考方案：一份提供统一的数据格式、数据适配器和分阶段实现思路；另一份提供 AMI、EPIC-KITCHENS、160ms 时间单位和质量验收路线。项目未使用自录数据，当前以公开真实数据为主。

目前已经完成真实数据构建、音视频编码和三模态联合训练。下一步将进一步验证用户输入的作用和连续预测的稳定性。

2. 数据集构建

数据构建是当前项目中最主要的工作。项目使用过 KTH、EPIC-KITCHENS 和 AMI 三类真实数据，但三者承担的任务不同，未把三个数据集混在一起训练。

数据源	规模	实际用途	是否进入当前统一训练
KTH	训练/验证/测试各 144 段	早期人体动作视频专项验证	否
EPIC-KITCHENS	64/32/32 段	普通生活场景动作专项验证	否
AMI-medium	训练 1,856；验证 548 条角色视角样本	当前文字、音频和视频统一训练主体	是

2.1AMI 主数据的构建方式

AMI 同时提供每位参与者的独立录音、近景视频、会议室 Corner 全景、说话人信息和词级时间戳，因此适合构建真实多人交互数据。先按完整会议划分训练和验证，保证两个集合中的会议和参与者不重复，再切分为互不重叠的 45 秒片段。

- 轮流指定一位参与者为当前智能体，其余三位作为用户侧参与者。
- 智能体独立麦克风和近景视频作为智能体流。
- 其他三路独立麦克风等权混合，作为用户侧音频。
- Corner 全景作为共享场景视频；其中同时包含用户和智能体，并不是纯用户视频。
- 官方转写和行为标注被映射到统一的 160ms 因果时间线。

数据划分	会议数量	角色视角样本	独立源时长	角色视角时长
训练	12	1,856	5.8000 小时	23.20 小时
验证	4	548	1.7125 小时	6.85 小时

目前数据集有约 7.5 小时不同的会议内容，但通过让四位参会者轮流扮演智能体，同一个 45 秒会议片段会分别从四个 focal-agent 角色视角使用，构造出了约 30 小时的训练样本；这些样本的预测目标不同，但底层会议内容存在重合。

2.2 AMI 样本示例




图 1 一条 AMI 训练样本的四路媒体预览：（a）当前智能体近景；（b）Corner 共享场景；（c）智能体独立麦克风波形；（d）其他参与者混合音频波形。

图中的人物和语音来自真实 AMI 会议，该样本长 45 秒，包含 17 个说话事件。智能体发言约 9.44 秒，用户单独发言约 23.84 秒，双方重叠约 4.48 秒，静默约 11.84 秒。重叠区间属于其他语音区间的子集，因此这些时长未作直接相加。

时间范围	交互状态	在训练中的含义
13.76-21.60 秒	用户持续发言	模型接收已经结束的用户词、用户音频和共享场景
21.60-22.40 秒	短暂重叠	保留重叠现象，并使用独立的语音监督区间
25.44-31.68 秒	智能体回应	构造智能体文字、音频和下一视频状态目标
40.32-41.44 秒	智能体简短回应	展示快速反馈与再次交接发言权

2.3 不同类型的会议样本

样本类型	智能体发言	用户单独发言	重叠发言	静默	打断起点
普通多人交互	9.44s	23.84s	4.48s	11.84s	7
重叠与打断	21.12s	12.00s	14.56s	12.00s	6
倾听场景	0.00s	38.72s	0.00s	6.40s	0

倾听样本中当前智能体没有说话，但仍有近景视频、共享场景、用户语音和行为标注。训练数据保留智能体开口、静默、倾听、点头、重叠和打断的片段，作为双工交互的重要状态。

2.4 从原始媒体到模型输入

数据流	原始形式	当前模型实际读取形式
智能体音频	16kHz 单声道独立麦克风	Mimi 离散编码 [8, 282, 2]
其他参与者音频	三路独立麦克风等权混合	Mimi 离散编码 [8, 282, 2]
智能体近景视频	25FPS, 224x192	Wan2.1 Wan-VAE latent [16, 282, 24, 28]
Corner 共享场景	25FPS, 224x192	Wan2.1 Wan-VAE latent [16, 282, 24, 28]
会议转写	说话人和词级时间戳	因果可见历史及下一词目标

每条 45 秒样本按约 160ms 组织为 282 个时间位置。音频末端不完整的编码帧以及不存在完整未来视频状态的位置会通过有效性 mask 排除，不作为训练目标。

3. 模型构建

原论文中的完整 Wan-Streamer 使用统一的因果 Transformer、严格因果的音视频 VAE、block-causal attention 和条件流匹配，目标是同时生成文字、音频和视频。论文没有公开足以直接复现的完整模型配置和权重。当前项目因此采用公开组件搭建最小实现，重点验证数据和因果机制。

部分	当前实现	承担的作用
文本骨干	SmolLM2-360M	表示因果文字历史并预测下一个 token
音频表示	Kyutai Mimi	将原始音频转换为离散音频 codes
视频表示	Wan2.1 Wan-VAE	将视频转换为紧凑的连续 latent
共享融合	128 维共享因果表示	融合文字、音频、视频、历史状态和 planner
输出头	文字、音频、视频三个预测头	分别预测下一个 token、当前音频 codes 和下一视频状态

当前统一模型约有 566.9 万可训练参数，三项训练损失都会向共享融合部分产生非零梯度。当前项目已经跑通了 Wan-Streamer 的一条基础链路：把真实会议中的文字、声音和画面对齐，让模型读取过去的信息，并预测下一小段文字、音频和视频状态。数据构建、因果时间关系和多模态预测都得到了验证，后续再考虑提升连续音视频生成效果。

START/CONTINUE/END 目前由外部 planner 提供，模型并未进行判断什么时候开始、继续或结束说话。

4. 训练与验证结果

目前主要结果来自 AMI-medium 验证集，并使用 7、17、29 三个随机种子进行重复。测试会议和未来保留会议尚未读取。

任务	当前结果	简单基线	备注说明
文本 next-token	Cross Entropy 约 2.93	移除用户/历史后约 4.89	因果文字历史可用于局部词预测
音频下一状态	准确率约 15.99%	复制上一状态约 14.58%	下一段 Mimi codes 预测超过复制基线
视频下一状态	MSE 约 0.0087	复制上一状态约 0.0111	误差相对复制基线降低约 21.3%

4.1 文本结果

文本专项实验在三个随机种子上得到了一致结果：正确的过去文字能够明显改善下一词预测，移除或打乱这些文字都会使结果变差。这说明模型确实会利用已经发生的文字内容。

统一三模态训练中，当前作用最稳定的是智能体自身的文字历史，用户文字对整体指标的影响相对较小。因此，现阶段文本部分主要实现了基于历史内容的连续预测，下一步将重点加强用户发言与智能体回复之间的联系。

4.2 音频和视频结果

音频和视频预测都优于直接复制上一状态的基线，说明模型学到了一部分短时变化规律。打乱或去除 Corner 共享场景视频后，三个随机种子的视频误差都会增大，说明模型确实使用了会议室中的共享画面。相比之下，用户音频的作用在不同实验中存在一定波动。目前最明确的结果是共享场景能够帮助视频预测，下一步将进一步拆分画面和声音来源，分析模型具体利用了哪些用户信息。

5. 遇到的问题和解决

前期在基础审计中发现了三个会影响结论可信度的问题：视频 latent 与 160ms 单元存在一格错位；最后一个单元曾监督不存在的完整未来画面；较长闭环可能读到 rollout 起点之后的真实智能体文字历史。

问题	修复后的规则
视频时间错位	使用当前边界 z_k 预测下一边界 $z_{(k+1)}$
末端无真实未来画面	终止单元不参与未来媒体监督
真实未来文字泄漏	文字历史只允许包含当前时刻之前已经生成或已结束的内容

6. 阶段总结与下一步计划

目前，项目已经完成真实 AMI 数据的整理，以及文字、音频和视频在统一因果时间线上的对齐与联合训练。实验表明，模型能够利用过去的文字和共享场景信息，音频、视频的下一状态预测也优于直接复制上一状态的简单方法。

下一步将在当前配置下进行短闭环实验，观察模型连续使用自身预测结果时的稳定性，并据此确定后续的数据和模型改进方向。

现阶段可以确认局部文字、音频和视频预测机制能够工作，共享场景视频也确实被模型使用。用户文字和用户音频的稳定增益目前还没有看到。下一步短闭环实验会继续检查这个最小版本能不能从单步预测走向有限的连续交互。

参考资料

- Wan Team. Video = World + Event Stream (Wan-Streamer v0.3), arXiv:2607.15038, 2026.
- Wan Team. Wan-Streamer v0.1: End-to-end Real-time Interactive Foundation Models, arXiv:2606.25041, 2026.
- AMI Meeting Corpus: 多人会议音视频、说话人及词级时间标注。
- EPIC-KITCHENS-100: 第一人称厨房动作视频数据集，CC BY-NC 4.0。
- KTH Human Actions: 人体动作视频数据集。
- Kyutai Mimi / Moshi: 当前项目使用的音频编码表示。
- Wan2.1 Wan-VAE: 当前项目使用的视频 latent 编码器。